



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO



FACULTAD DE
INGENIERÍA

Universidad Nacional de Cuyo

FACULTAD DE INGENIERÍA

PREDICCIÓN DE PRECIOS DE CRIPTOMONEDAS CON ARIMA Y PROPHET

Proyecto Final
Inteligencia Artificial I

MOLINA, Mauro
FLORES, Daniel Emiliano

Marzo 2022

Índice

1. Introducción	2
1.1. Criptomonedas	2
1.1.1. Precios	3
1.2. Series Temporales	3
1.2.1. Análisis de las Series Temporales	4
1.2.2. Coeficiente de autocorrelación	5
2. Procesos Estocásticos	6
2.1. Características	6
2.2. Procesos estocásticos estacionarios	7
2.3. Formalización de funciones	8
2.3.1. Estacionaridad y estimación de momentos	8
2.4. Ruido blanco	9
3. Modelos estacionarios	9
3.1. Modelo Lineal General	9
3.2. Procesos Autoregresivos de Medias Móviles	11
3.2.1. $ARMA(1, 1)$	11
3.2.2. $ARMA(p, q)$	13
4. Modelos no estacionarios	13
4.1. Modelos ARIMA(p,d,q)	14
5. Prophet	15
5.1. Elementos	15
5.2. Incertidumbre	16
6. Metodología	16
7. Análisis de Resultados	17
7.1. Métricas	17
7.2. $ARIMA(p, d, q)$	17
7.2.1. Predicciones aleatorias	19
7.3. Prophet	20
7.3.1. Predicciones Aleatorias	20
7.4. Comparación de Modelos	20
8. Conclusión	21

1. Introducción

1.1. Criptomonedas

Una criptomoneda es un activo digital que emplea un cifrado para garantizar integridad, autenticidad y confidencialidad de las transacciones, es decir, funcionan como moneda de cambio y solucionan los problemas que las monedas de cambio tradicionales presentan.

El dinero reemplazó a la economía de trueque, donde las transacciones se rigen bajo la premisa “¿cuánto de mi producto vale el tuyo?”. Para sustituir esta modalidad, el valor de un producto o servicio se mide en función del dinero.

La moneda se puede abstraer como cualquier objeto (real o no) que resuelva sea capaz de cumplir esta característica. Formalmente, debe cumplir los siguientes aspectos:

- Debe servir como moneda de cambio, es decir, quien aporta el capital recibe un bien o servicio a cambio.
- Debe servir de referencia de valor, es decir, poder determinar, a través de dicha moneda, cuánto vale un bien o servicio.
- Debe servir como reserva de valor, es decir, que su valor no se vea modificado con el paso del tiempo.

Estos parámetros son determinados por la sociedad, según el uso y confianza que le tengan a la moneda.

Las criptomonedas no son diferentes a las monedas corrientes, con algunas salvedades:

- No hay un ente central del que dependamos (como el banco) que regule las transacciones.
- Mantiene total privacidad, ya que toda la información está encriptada y nadie sabe la información del dueño del dinero.
- Evita problemas de “devaluación” de la moneda, ya que no depende de factores socio-económicos (como la emisión monetaria)

Este sistema funciona bajo el modelo Peer-To-Peer (P2P), donde cada usuario funciona como cliente o servidor de otro, según corresponda. Es decir, si queremos saber cuanto dinero tiene una persona, debemos mantener un registro global, que incluye a todas las transacciones que han ocurrido desde el origen de una determina criptomoneda. Este registro debe ser público, para que cualquier persona pueda consultarlo en cualquier momento.

Pero si existe este registro ¿cómo puede existir la privacidad?

La privacidad se sigue respetando, ya que realmente no se sabe a quien pertenece el dinero que figura en dichas transacciones. Esta cadena de transacciones se conoce como **BlockChain** (cadena de bloques). La idea aquí es formar una LinkedList, donde cada bloque apunta al anterior. Las personas encargadas de añadir los bloques al registro de transacciones se conocen como **mineros**. Una vez que se añade el bloque a la cadena, se avisa al resto de los mineros que añadan dicho en su registro.

Nótese que un bloque puede contener muchas transacciones.

1.1.1. Precios

El precio se determina por la oferta y la demanda. Cuando se incrementa la demanda, el precio sube, y cuando cae la demanda, el precio baja. Hay un número limitado de criptomonedas en circulación y las nuevas son creadas a una velocidad predecible y decreciente, esto significa que la demanda debe seguir este nivel de inflación para mantener un precio estable. Este es el caso del Bitcoin.

Sin embargo, en la actualidad es posible crear tokens con emisión ilimitada, a disposición de reglas establecidas (por ejemplo, ADA) o el sistema de recompensas (CAKE).

Al concluir el desarrollo teórico del presente informe, se evaluarán los resultados sobre las criptomonedas Bitcoin [BTC], Ether [ETH] y Ada [ADA].

1.2. Series Temporales

Una serie de tiempo es una forma estructurada u ordenada de presentar los datos, en donde un parámetro temporal regular o irregular (fecha, hora, semana, día, mes, año, etc.) lleva asociado un valor.

Se usan para estudiar la relación causa-consecuencia entre diversas variables que cambian con el tiempo. Desde el punto de vista probabilístico, una serie temporal es una sucesión de variables aleatorias indexadas según parámetro creciente con el tiempo, que conforman un conjunto ordenado de datos y coexisten de forma dependiente entre ellas.

Con la ayuda del machine learning, puede servir para detectar patrones implícitos en el comportamiento de los fenómenos con el solo hecho de ordenarlos según un parámetro temporal.

Por ejemplo: Un caso trivial podría ser el de realizar una serie temporal con las ventas del año de una heladería. El resultado en este caso es trivial. Las ventas alcanzan un máximo relativo en verano y un mínimo relativo en invierno.

El instrumento de análisis que se suele utilizar es un modelo que permita reproducir el comportamiento de la variable de interés. Estos pueden ser:

- Univariantes: la serie temporal es analizada únicamente en función de su propio pasado;
- Multivariantes: son analizadas varias series temporales, en consecuencia a la suposición de dependencia o relación entre ellas.

Describimos matemáticamente una serie temporal univariante como un conjunto de observaciones, de tamaño T , sobre una variable Y :

$$Y_t, \quad t = 1, 2, \dots, T \quad (1)$$

El pronóstico de la serie temporal implica extender los valores históricos hacia el futuro, tales como el periodo y el horizonte (cantidad de periodos proyectados). Si es un modelo univariante, se pronostica únicamente en términos de valores pasados Y_t , lo que comunmente llamamos extrapolación.

Si una serie temporal es extrapolable exactamente, decimos que ésta es determinista. Sin embargo, la gran parte de ellas no lo son y están condicionadas a una distribución de probabilidad dependiente de sus valores pasados.

Los modelos utilizados para caracterizar una serie temporal responden siempre a una misma fórmula:

$$Y_t = S_t + a_t \quad (2)$$

Donde S_t indica el comportamiento regular de la variable -conocida como parte sistémica- y a_t es el comportamiento aleatorio -también denominada *innovación*-.

En modelos de series univariantes, S_t se determina únicamente en función del pasado de la serie:

$$S_t = f(Y_t, Y_{t-1}, Y_{t-2}, \dots) \quad (3)$$

1.2.1. Análisis de las Series Temporales

Las series temporales pueden ser descritas en función de sus componentes. En ciertos modelos, son resultado de cuatro componentes que actúan en conjunto:

- **Tendencia secular o regular.** Indica el crecimiento, decrecimiento o estacionalidad general y persistente del fenómeno observado, es la componente que refleja la evolución a largo plazo. La denotaremos como B_t .
- **Variación estacional o variación cíclica regular.** Está relacionada con el movimiento periódico de corto plazo. Se trata de una componente causal debida a la influencia de ciertos fenómenos que se repiten de manera periódica en un periodo de tiempo. Por ejemplo, si el periodo es un año, las estaciones son una variación cíclica regular, si el periodo es una semana, los fines de semana son la variación estacional, si el periodo es un día, las horas son la variación estacional. Recopila las oscilaciones que se producen en esos periodos temporales regulares. La denotaremos como E_t .
- **Variación cíclica.** Recoge las oscilaciones periódicas de amplitud superior a un año. Movimientos normalmente irregulares alrededor de la tendencia, en las que, a diferencia de las variaciones estacionales, tiene un periodo y amplitud variables. En otras palabras, son variaciones estacionales de largo plazo y de eventos irregulares. Esta componente puede no existir, ya que la serie temporal puede no ser cíclica en ningún momento. La denotaremos como C_t .
- **Variación aleatoria o ruido.** Incluye todos aquellos factores que no muestran ninguna regularidad, debidos a fenómenos de carácter ocasional. Por ejemplo: Tormentas en relación con las cosechas de alguna verdura. La denotaremos como R_t .

Estas componentes generan los siguientes tipos de series:

- **Aditivas.** Sumando sus componentes: $X_t = B_t + E_t + C_t + R_t$
- **Multiplicativas.** Multiplicando sus componentes: $X_t = B_t * E_t * C_t * R_t$
- **Mixtas.** Sumando y multiplicando sus componentes, por lo que existen varias alternativas. Por ejemplo: $X_t = B_t + E_t * C_t * R_t$

Sin embargo, la clasificación arriba descrita no es utilizada para modelos ARIMA. En estos, se trata de obtener la representación de la serie en términos de la interrelación temporal entre sus elementos.

1.2.2. Coeficiente de autocorrelación

Uno de los instrumentos utilizados es el coeficiente de correlación ρ_{xy} entre dos variables x_t y y_t . Este coeficiente mide el grado de asociación lineal entre ellas:

$$\rho_{xy} = \frac{\text{cov}(x, y)}{\sqrt{V(x)V(y)}} \quad (4)$$

donde, por definición, $\rho_{xy} \in [-1, 1]$.

De este coeficiente de correlación poblacional podemos estimar el coeficiente de correlación muestral:

$$r_{xy} = \frac{\sum_{t=1}^T (x_t - \bar{x})(y_t - \bar{y})}{\sqrt{\sum_{t=1}^T (x_t - \bar{x})^2 \sum_{t=1}^T (y_t - \bar{y})^2}} \quad (5)$$

Si tenemos T observaciones Y_1, \dots, Y_T , podemos crear $(T-1)$ pares de observaciones $(Y_1, Y_2), \dots, (Y_{T-1}, Y_T)$. Es decir, consideramos Y_1, \dots, Y_{T-1} como una variable y Y_2, \dots, Y_T como otra para definir la correlación entre ambas variables Y_t, Y_{t+1} :

$$r_{Y_t Y_{t+1}} = \frac{\sum_{t=1}^{T-1} (Y_t - \bar{Y}_{(1)})(Y_{t+1} - \bar{Y}_{(2)})}{\sqrt{\sum_{t=1}^{T-1} (Y_t - \bar{Y}_{(1)})^2 \sum_{t=1}^{T-1} (Y_{t+1} - \bar{Y}_{(2)})^2}} \quad (6)$$

Donde $\bar{Y}_{(1)}$ y $\bar{Y}_{(2)}$ es la media muestral de las primeras $T-1$ observaciones y la media muestral de las últimas $T-1$ observaciones, respectivamente.

La expresión anterior es aproximadamente:

$$r_{Y_t Y_{t+1}} \approx r_1 = \frac{\sum_{t=1}^{T-1} (Y_t - \bar{Y})(Y_{t+1} - \bar{Y})}{\sum_{t=1}^T (Y_t - \bar{Y})^2} \quad (7)$$

El subíndice indica el intervalo de correlación lineal de las observaciones analizadas. En el caso anterior descrito, r_1 analiza observaciones sucesivas y se denomina *coeficiente de autocorrelación de primer orden*.

Por tanto, el coeficiente de autocorrelación de orden k viene dado por:

$$r_k = \frac{\sum_{t=1}^{T-k} (Y_t - \bar{Y})(Y_{t+k} - \bar{Y})}{\sum_{t=1}^T (Y_t - \bar{Y})^2} \quad (8)$$

Para interpretar el conjunto de los coeficientes de autocorrelación de una serie temporal se utiliza un *correlograma*, que es un gráfico que agrupa los k coeficientes de autocorrelación.

Estos suelen comenzar en $k = 1$ puesto que un $k = 0$ en la Ecuación (8) siempre es 1.

1. Si una serie es puramente aleatoria, $r_k \approx 0$ para cualquier $k \neq 0$ siendo T suficientemente grande.
2. Series sin tendencia oscilantes en torno a una media constante:

- a) Si contiene observaciones por encima de la media seguidas de una o más observaciones por encima de la media (lo mismo para observaciones por debajo de la media), entonces r_k decrece tendiendo a cero rápidamente a medida que aumenta k .
 - b) Si contiene observaciones alternantes por encima y debajo de la media, el correlograma presenta valores decrecientes que alternan su signo.
3. Si la serie contiene una tendencia, los valores de r_k no decrecerán a cero rápidamente. Esto se debe a que un valor observado tiene sucesivos valores que estarán por encima (o debajo) de la media. Este tipo de comportamiento nos da poca información.
 4. Si una serie presenta algún tipo de ciclo, el correlograma también presentará una oscilación a la misma frecuencia. En las series con un comportamiento cíclico permanente, el correlograma da de nuevo poca información porque lo domina el comportamiento cíclico presente en los datos.

2. Procesos Estocásticos

Un proceso estocástico es una familia de variables aleatorias relacionadas entre sí y que siguen una ley de distribución conjunta. Lo denotaremos por:

$$\dots, Y_{t-2}, Y_{t-1}, Y_t, Y_{t+1}, Y_{t+2}, \dots \text{ o } Y_t$$

A simple vista podemos entender que fijar $t = t_0$ nos da una variable aleatoria de la secuencia *presumiblemente ordenada*¹. Además, llamaremos *realización* del proceso a la asignación de un valor a cada una de las variables aleatorias del mismo.

En virtud de lo anterior, una serie temporal $Y_t, Y_{t+1}, Y_{t+2}, \dots$ se puede interpretar como una realización muestral de un proceso estocástico para un número finito de periodos $t = 1, 2, \dots, T$.

2.1. Características

Función de distribución. Incluye todas las funciones de distribución para cualquier subconjunto finito de variables aleatorias del proceso:

$$F[Y_{t_i}, Y_{t_{i+1}}, \dots, Y_{t_n}] \text{ siendo } n \text{ finito.}$$

Momentos del proceso estocástico. El primer momento de un proceso estocástico es el conjunto de las medias de todas las variables aleatorias del proceso:

$$E(Y_t) = \mu_t < \infty, \quad t = 0, \pm 1, \pm 2, \dots \quad (9)$$

El segundo momento viene dado por el conjunto de las varianzas de todas las variables aleatorias del proceso y por las covarianzas entre todo par de variables aleatorias:

¹El orden en la sucesión de observaciones es único en una serie temporal. Alterarlo implicaría modificar las características de la serie.

$$\begin{aligned} V(Y_t) &= E[Y_t - \mu_t]^2 = \sigma_t^2 < \infty, \quad t = 0, \pm 1, \pm 2, \dots \\ cov(Y_t, Y_s) &= E[Y_t - \mu_t][Y_s - \mu_s] = \gamma_{t,s} \quad \forall t, s \quad (t \neq s) \end{aligned} \quad (10)$$

2.2. Procesos estocásticos estacionarios

Para hacer análisis y predicciones consistentes a una serie de tiempo, es necesario que la estructura probabilística que subyace en el proceso estocástico sea estable en el tiempo. Es decir, las regularidades del comportamiento pasado deben ser capaces de proyectarse a futuro. Estas características de un proceso estocástico se las conoce como *estacionariedad*.

Estacionariedad estricta. Un proceso estocástico es estrictamente estacionario si y solo si

$$F[Y_{t_i}, Y_{t_{i+1}}, \dots, Y_{t_n}] = F[Y_{t_i+k}, Y_{t_{i+1}+k}, \dots, Y_{t_n+k}] \quad (11)$$

en otras palabras, si la función de distribución de cualquier conjunto finito de variables aleatorias del proceso no se altera si se desplaza k periodos en el tiempo.

Estacionariedad en covarianza. Un proceso estocástico es estacionario en covarianza si y solo si:

1. Es estacionario en media, es decir, todas las variables aleatorias tienen la misma media y es finita:

$$E(Y_t) = \mu < \infty, \quad \forall t \quad (12)$$

2. Todas las variables aleatorias tienen la misma varianza y es finita:

$$V(Y_t) = E[Y_t - \mu]^2 = \sigma_Y^2 < \infty, \quad \forall t \quad (13)$$

3. La covarianza lineal entre dos variables aleatorias del proceso que disten k periodos de tiempo es la misma que existe entre cualesquiera otras dos variables que estén separadas también k periodos. También conocemos esta propiedad como *autocovarianza*:

$$cov(Y_t, Y_s) = E[Y_t - \mu][Y_s - \mu] = \gamma_{t,s} = \gamma_{|t-s|} = \gamma_k \quad \forall k \quad (14)$$

Finalmente, decimos que un proceso estocástico estacionario en covarianza está caracterizado si se conoce:

$$\mu, \quad V(Y_t), \quad \gamma_k, \quad k = 0, \pm 1, \pm 2, \dots$$

Si bien las series económicas no presentan comportamientos estacionarios, particularmente las series temporales que reflejan el precio de una criptomoneda, se procederá a proponer modelos que para procesos estacionarios. A partir de estos se puede modelar para un proceso no estacionario.

2.3. Formalización de funciones

Función de autocovarianzas. Es una función de k (número de periodos de separación entre las variables) que recoge el conjunto de las autocovarianzas del proceso estocástico estacionario:

$$\gamma_k, k = 0, 1, 2, \dots$$

Es una función simétrica:

$$\gamma_k = \gamma_{-k}$$

y, además, incluye la varianza del proceso para $k = 0$:

$$\gamma_0 = V(Y_t).$$

Función de autocorrelación. Al igual que la anterior, recoge toda la información de la estructura dinámica lineal del proceso estocástico con la diferencia de que es independiente de las unidades de la variable.

El coeficiente de autocorrelación de orden k de un proceso estocástico estacionario mide el grado de asociación lineal existente entre dos variables aleatorias del proceso separadas por k periodos:

$$\rho_k = \frac{\text{cov}(Y_t, Y_{t+k})}{\sqrt{V(Y_t) * V(Y_{t+k})}} = \frac{\gamma_k}{\sqrt{\gamma_0 * \gamma_0}} = \frac{\gamma_k}{\gamma_0} \quad (15)$$

donde

$$|\rho_k| \leq 1, \forall k$$

La función de autocorrelación de un proceso estocástico estacionario es una función de k que recoge el conjunto de los coeficientes de autocorrelación del proceso y se denota por ρ_k . La función de autocorrelación se suele representar gráficamente por medio de un correlograma.

El coeficiente de autocorrelación de orden 0 es, por definición, 1. Genera una función simétrica, por lo que un correlograma solo representa valores positivos de k . Esta función, además, tiende a cero rápidamente a medida que k tiende a infinito. Ésta última afirmación es correcta cuando tenemos un proceso estocástico estacionario, condición que se buscará y se hará énfasis en el análisis de resultados.

De estas premisas, al observar un correlograma podemos concluir que su correspondiente serie no es estacionaria si la función no decrece rápidamente.

2.3.1. Estacionaridad y estimación de momentos

Si la serie temporal (Y_1, Y_2, \dots, Y_T) no fuera estacionaria, ya no tendríamos una única media, ni una única varianza y las autocorrelaciones serían demasiadas. La estacionaridad es, desde luego, una restricción necesaria para estimar los momentos de un proceso estocástico.

2.4. Ruido blanco

El proceso estocástico ruido blanco, denotado w_t , lo definimos como:

$$\begin{aligned} E(w_t) &= 0, \forall t \\ V(w_t) &= \sigma^2, \forall t \\ Cov(w_t, w_s) &= 0, \forall t \neq s \end{aligned}$$

Un proceso ruido blanco $w_t \sim RB(0, \sigma^2)$ es estacionario si la varianza σ^2 es finita, con función de autocovarianzas:

$$\gamma_k = \begin{cases} \sigma^2, & k = 0 \\ 0, & k > 0 \end{cases}$$

y función de autocorrelación:

$$\rho_k = \begin{cases} 1, & k = 0 \\ 0, & k > 0 \end{cases}$$

3. Modelos estacionarios

La estructura de dependencia temporal de una serie está recogida en la función de autocovarianzas y/o en la función de autocorrelación. Mediante un modelo ARMA, se tratará de reproducir el comportamiento general y posteriormente predecir con la ayuda del mismo.

3.1. Modelo Lineal General

Anteriormente descompusimos una serie temporal univariante en dos componentes (2). Ahora, nuestra parte sistémica contiene la información para construir el modelo mientras que la innovación contendrá valores sin dependencia entre sí, tanto en valores pasados como con su parte sistémica. La innovación, como se habrá podido intuir, es el ruido blanco.

Así, un modelo teórico capaz de describir un comportamiento de una serie temporal con media cero sería:

$$Y_t = f(Y_{t-1}, Y_{t-2}, \dots) + w_t, \quad t = 1, 2, \dots \quad (16)$$

El proceso estocástico puede responder a un proceso de Gauss, por lo que Y_t puede expresarse como una combinación lineal de sus valores pasados infinitos más una innovación:

$$Y_t = \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \dots + w_t \quad t = 1, 2, \dots \quad (17)$$

donde Y_t es un proceso estacionario y π_i son constantes con $\phi_t \neq 0$.

Para que esto suceda, es preciso que el proceso sea *no anticipante*: cualquier valor Y_i no debe depender de valores futuros. En adición, el proceso debe ser *invertible*, es decir que el presente dependa de forma convergente con su propio pasado. A medida que nos alejemos en el tiempo, la influencia de Y_k debe disminuir. Esta restricción viene dada por:

$$\sum_{i=1}^{\infty} \pi_i^2 < \infty$$

Operador de retardos. Lo definimos como:

$$BY_t = Y_{t-1} \quad (18)$$

particularmente:

$$B^2Y_t = B(BY_t) = BY_{t-1} = Y_{t-2}$$

y generalmente:

$$B^kY_t = Y_{t-k} \quad (19)$$

Reescribimos (17) en función del operador de retardos:

$$\begin{aligned} Y_t &= (\pi_1 B + \pi_2 B^2 + \dots)Y_t + w_t \\ (1 - \pi_1 B - \pi_2 B^2 - \dots)Y_t &= w_t \end{aligned}$$

Si $(1 - \pi_1 B - \pi_2 B^2 - \dots) = \pi_{\infty}(B)$:

$$\pi_{\infty}(B)Y_t = w_t \quad (20)$$

Teniendo presente que $\pi_{\infty}(B)$ es un polinomio de orden infinito, es necesario aproximarlos a uno de orden finito -los modelos a desarrollar deberán representar procesos estocásticos acotados en el tiempo:

$$\pi_{\infty}(B) \approx \frac{\phi_p(B)}{\theta_q(B)} \quad (21)$$

donde:

$$\begin{aligned} \phi_p(B) &= 1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p \\ \theta_q(B) &= 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q \end{aligned} \quad (22)$$

Sustituyendo (21) en (20):

$$\phi_p(B)Y_t = \theta_q(B)w_t \quad (23)$$

Por lo tanto, este modelo lineal general admite tres representaciones:

- *Puramente regresiva, $AR(\infty)$:* el valor presente de la variable se representa en función de su propio pasado más una innovación contemporánea.
- *Puramente de medias móviles, $MA(\infty)$:* el valor presente de la variable se representa en función de todas las innovaciones pasadas y presente.
- *Finita:*

$$\begin{aligned} (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)Y_t &= (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)w_t \\ Y_t &= \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + w_t - \theta_1 w_{t-1} - \theta_2 w_{t-2} - \dots - \theta_q w_{t-q} \end{aligned} \quad (24)$$

Este modelo se denomina *Autorregresivo de Medias Móviles* de orden (p, q) . En él, el valor de Y_t depende del pasado de Y hasta el momento $t - p$ de la innovación contemporánea y su pasado hasta el momento $t - q$.

3.2. Procesos Autoregresivos de Medias Móviles

Como hemos señalado anteriormente, la ecuación 24 es una aproximación finita al modelo lineal general tanto en su forma $AR(\infty)$ como $MA(\infty)$.

De hecho, si es estacionario su representación $MA(\infty)$ es

$$Y_t = \frac{\theta_q(B)}{\phi_p(B)} w_t \rightarrow Y_t = \psi_\infty(B) w_t \rightarrow Y_t = w_t + \psi_1 w_{t-1} + \psi_2 w_{t-2} + \dots \quad (25)$$

y si es invertible, su representación $AR(\infty)$ es

$$\frac{\phi_p(B)}{\theta_q(B)} Y_t = w_t \rightarrow \pi_\infty(B) Y_t = w_t \rightarrow Y_t = w_t + \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \dots \quad (26)$$

Teorema de estacionariedad. Un proceso autoregresivo de medias móviles finito $ARMA(p, q)$ es estacionario sí y solo sí el módulo de las raíces del polinomio autorregresivo $\phi(B)$ está fuera del círculo unidad.

Las condiciones de estacionariedad del modelo $ARMA(p, q)$ vienen impuestas por la parte autorregresiva, dado que la parte de medias móviles finita siempre es estacionaria.

Para comprobar si el modelo $ARMA(p, q)$ es no anticipante e invertible, se estudia su representación autorregresiva general.

Teorema de invertibilidad. Un proceso autorregresivo de medias móviles finito $ARMA(p, q)$ es invertible sí y solo sí el módulo de las raíces del polinomio de medias móviles $\theta_p(B)$ está fuera del círculo unidad.

Las condiciones de invertibilidad del modelo $ARMA(p, q)$ vienen impuestas por la parte de medias móviles, dado que la parte autorregresiva finita siempre es invertible porque está directamente escrita en forma autorregresiva.

El modelo $ARMA(p, q)$ tiene media cero, varianza constante y finita y una función de autocovarianzas infinita. La función de autocorrelación es infinita decreciendo rápidamente hacia cero pero sin truncarse.

3.2.1. $ARMA(1, 1)$

En este modelo, Y_t se determina en función de su pasado hasta el primer retardo, la innovación contemporánea y el pasado de la innovación hasta el retardo 1:

$$Y_t = \phi Y_{t-1} + w_t - \theta w_{t-1} \quad w_t \sim RB(0, \sigma^2) \quad t = 1, 2, \dots \quad (27)$$

La memoria de este proceso es larga debido a que presenta la estructura autorregresiva. Es decir, una perturbación w_t ingresa al sistema afectando a Y_t y, a través de él, al futuro. Sin embargo, por su estructura de medias móviles, la perturbación w_t afecta directamente a Y_t y Y_{t-1} .

$$\begin{array}{cccccccccccc}
\dots & \rightarrow & Y_{t-2} & \rightarrow & Y_{t-1} & \rightarrow & Y_t & \rightarrow & Y_{t+1} & \rightarrow & Y_{t+2} & \rightarrow & \dots \\
& & \uparrow & \nearrow & \uparrow & \nearrow & \uparrow & \nearrow & \uparrow & \nearrow & \uparrow & \nearrow & \\
\dots & & w_{t-2} & & w_{t-1} & & w_t & & w_{t+1} & & w_{t+2} & &
\end{array}$$

Por el teorema de estacionariedad, es necesario y suficiente comprobar que las raíces del polinomio autorregresivo estén fuera del círculo unidad:

$$\phi_1(B) = 1 - \phi B = 0 \quad \rightarrow \quad B = \frac{1}{\phi} \quad \rightarrow \quad |B| = \left| \frac{1}{\phi} \right| \quad \rightarrow \quad |\phi| < 1$$

Por el teorema de invertibilidad, es necesario y suficiente comprobar que las raíces del polinomio de medias móviles estén fuera del círculo unidad:

$$\theta_1(B) = 1 - \theta B = 0 \quad \rightarrow \quad B = \frac{1}{\theta} \quad \rightarrow \quad |B| = \left| \frac{1}{\theta} \right| \quad \rightarrow \quad |\theta| < 1$$

La media de este proceso es:

$$\begin{aligned}
E(Y_t) &= E(\phi Y_{t-1} + w_t - \theta w_{t-1}) = \phi E(Y_t) \\
&\rightarrow (1 - \phi)E(Y_t) = 0 \\
&\rightarrow E(Y_t) = 0
\end{aligned}$$

Para determinar la función de covarianzas, tenemos en cuenta que:

$$E(Y_{t-1}w_{t-1}) = E[(\phi Y_{t-2} + w_{t-1} - \theta w_{t-2})w_{t-1}] = E(w_{t-1})^2 = \sigma^2$$

En tanto, dicha función es:

$$\begin{aligned}
\gamma_0 &= E(Y_t - E(Y_t))^2 = E(Y_t)^2 = E(\phi Y_{t-1} + w_t - \theta w_{t-1})^2 \\
&= \phi^2 E(Y_{t-1})^2 + E(w_t)^2 + \theta^2 E(w_{t-1})^2 + 2\phi E(Y_{t-1}w_t) - 2\phi\theta E(Y_{t-1}w_{t-1}) - 2\theta E(w_t w_{t-1}) \\
&= \phi^2 \gamma_0 + \sigma^2 + \theta^2 \sigma^2 - 2\phi\theta \sigma^2 \\
&= \phi^2 \gamma_0 + (1 + \theta^2 - 2\phi\theta) \sigma^2 \\
\rightarrow \gamma_0 &= \frac{(1 + \theta^2 - 2\phi\theta) \sigma^2}{1 - \phi^2}
\end{aligned}$$

$$\begin{aligned}
\gamma_1 &= E(Y_t - E(Y_t))(Y_{t-1} - E(Y_{t-1})) = E(Y_t Y_{t-1}) \\
&= E[(\phi Y_{t-1} + w_t - \theta w_{t-1})Y_{t-1}] \\
&= \phi E(Y_{t-1})^2 + E(Y_{t-1}w_t) - \theta E(Y_{t-1}w_{t-1}) \\
&= \phi \gamma_0 - \theta \sigma^2
\end{aligned}$$

$$\begin{aligned}
\gamma_2 &= E(Y_t - E(Y_t))(Y_{t-2} - E(Y_{t-2})) = E(Y_t Y_{t-2}) \\
&= E[(\phi Y_{t-1} + w_t - \theta w_{t-1})Y_{t-2}] \\
&= \phi E(Y_{t-1}Y_{t-2}) + E(Y_{t-2}w_t) - \theta E(Y_{t-2}w_{t-1}) \\
&= \phi \gamma_1
\end{aligned}$$

Es decir que la función de autocovarianzas para un $ARMA(1, 1)$ es:

$$\gamma_k = \begin{cases} \frac{(1+\theta^2-2\phi\theta)\sigma^2}{1-\phi^2}, & k = 0 \\ \phi\gamma_0 - \theta\sigma^2, & k = 1 \\ \phi\gamma_{k-1}, & k > 1 \end{cases}$$

La función γ_k nos brinda un formalismo a lo expresado previamente. La autocovarianza de orden 0 cuenta con términos provenientes de la parte autorregresiva y de medias móviles. De forma similar, en la autocovarianza de orden 1 tenemos términos de $AR(1)$ $MA(1)$. Finalmente, órdenes superiores dependen exclusivamente de la autorregresión.

La función de autocorrelación de un $ARMA(1, 1)$ es:

$$\rho_k = \begin{cases} \phi - \frac{\theta\sigma^2}{\gamma_0}, & k = 1 \\ \phi\rho_{k-1} & \end{cases}$$

La FAC presenta la misma estructura que la función de autocovarianzas, es decir, es una función infinita cuyo primer coeficiente, ρ_1 , depende de los parámetros autorregresivos y de medias móviles, pero a partir del retardo 2, decrece exponencialmente, siguiendo la estructura dada por la parte autorregresiva de orden 1.

3.2.2. $ARMA(p, q)$

Los resultados obtenidos para $ARMA(1, 1)$ son generalizables para este modelo. Observemos: para los primeros q coeficientes ρ_1, \dots, ρ_q dependerán de los parámetros autorregresivos y de medias móviles, mientras que los siguientes no dependerán del parámetro de medias móviles. En consecuencia, la función de autocorrelación decrecerá rápidamente a cero.

Es posible modificar $ARMA(p, q)$ de tal forma que su media no sea nula añadiendo una constante al proceso estacionario:

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p} + w_t - \theta_1 w_{t-1} - \theta_2 w_{t-2} - \dots - \theta_q w_{t-q} \quad w_t \sim RB(0, \sigma^2) \quad (28)$$

La única diferencia respecto al modelo sin la constante δ es que su media no es cero:

$$\begin{aligned} E(Y_t) &= E(\delta + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + w_t + \theta_1 w_{t-1} + \dots + \theta_q w_{t-q}) \\ &= \delta + \phi_1 E(Y_t) + \dots + \phi_p E(Y_t) \\ \rightarrow \delta &= (1 - \phi_1 - \dots - \phi_p) E(Y_t) \\ E(Y_t) &= \frac{\delta}{(1 - \phi_1 - \dots - \phi_p)} \end{aligned}$$

4. Modelos no estacionarios

Lo visto hasta el momento responde a la estacionariedad en covarianza, es decir, media y varianza constantes y finitas junto a autocovarianzas independientes del tiempo. Sin embargo, en series económicas este comportamiento no se replica.

En este caso, quitaremos el supuesto de que tenemos una serie estacionaria en covarianza y mediante algún método transformaremos la serie para estabilizar la covarianza.

4.1. Modelos ARIMA(p,d,q)

Supongamos el modelo $ARMA(p, q)$:

$$\Phi_p(B)Y_t = \Theta_q(B)w_t$$

donde el polinomio AR se puede factorizar en función de sus p raíces B_1, B_2, \dots, B_p :

$$\Phi_p(B) = (1 - B_1^{-1}B)(1 - B_2^{-1}B)\dots(1 - B_p^{-1}B)$$

Si suponemos que $p-1$ raíces son estacionarias (con módulo fuera del círculo unidad) y una de ellas es unitaria, $B_i = 1$, entonces el polinomio AR se puede reescribir como sigue:

$$\begin{aligned}\Phi_p(B) &= (1 - B_1^{-1}B)(1 - B_2^{-1}B)\dots(1 - B_p^{-1}B) = \varphi_{p-1}(B)(1 - (-1)^{-1}B) \\ \Phi_p(B) &= \varphi_{p-1}(B)(1 - B)\end{aligned}$$

donde el polinomio $\varphi_{p-1}(B)$ es el producto de los $p-1$ polinomios de orden 1 asociados a las raíces B_j asociadas al círculo unidad. Necesariamente se aclara que es un polinomio estacionario.

Sustituyendo en el modelo $ARMA(p, q)$ obtenemos:

$$\begin{aligned}\varphi_{p-1}(B)(1 - B)Y_t &= \Theta_q(B)w_t \\ \varphi_{p-1}(B)\Delta Y_t &= \Theta_q(B)w_t\end{aligned}\tag{29}$$

Nótese que Δ es el polinomio que recoge la raíz unitaria.

La ecuación 29 representa a un modelo con un comportamiento no estacionario ya que contiene una raíz unitaria. Un proceso Y_t con estas características se le denomina *proceso integrado de orden 1*

El proceso AR puede contener más de una raíz unitaria, por lo que se puede generalizar el modelo 29 como:

$$\varphi_{p-d}(B)\Delta^d Y_t = \Theta_q(B)w_t\tag{30}$$

Así mismo, el polinomio $\varphi_{p-d}(B)$ es estacionario porque sus $p-d$ raíces tienen módulo fuera del círculo unidad, y el polinomio Δ^d , de orden d , contiene las d raíces unitarias no estacionarias.

Este proceso Y_t con estas características se denomina *proceso integrado de orden d* y se denota por $Y_t \sim I(d)$.

Formalmente, un proceso Y_t es integrado de orden d , $Y_t \sim I(d)$, si Y_t no es estacionario, pero su diferencia de orden d , $\Delta^d Y_t$, sigue siendo un proceso $ARMA(p-d, q)$ estacionario e invertible.

5. Prophet

Este modelo surge por las limitaciones que presentan los modelos SARIMAX, como estacionariedad y valores igualmente espaciados en el tiempo (siendo que esto puede variar mucho en la realidad).

La idea de este algoritmo es plantear a la serie temporal como la suma de 4 componentes:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t \quad (31)$$

donde:

- $g(t)$. Describe la tendencia lineal o de crecimiento logístico de largo plazo, creando una función definida por partes en los puntos de cambio (simplificando la predicción).
Los puntos de cambio son momentos en los datos donde los datos cambian de dirección.
- $s(t)$. Función que define la estacionalidad (anual, mensual, semanal, etc.)
- $h(t)$. Hechos concretos que pueden alterar los valores de la serie (vacaciones, feriados, paros, etc.), a definirse por el usuario
- ϵ_t . Término de error.

5.1. Elementos

Prophet intenta ajustar las funciones (lineales o no) a los datos dando más o menos importancia a los distintos efectos, es decir, un modelo muy parametrizable:

1. **Tendencia lineal $g(t)$.** Para calcular el termino $g(t)$, Prophet ofrece 2 alternativas.
 - Crecimiento Logístico. Estos casos corresponden a situaciones en donde se da una saturación que no permite el crecimiento más allá de un límite determinado. Se aplica una sigmoide pero un poco cambiada.
 - C: Capacidad de Carga. Define la carga máxima que puede llegar a tomar la curva. Nótese que este valor puede no ser fijo y depender de otro parámetro externo $C(t)$.
 - k: Es la tasa de crecimiento. Define qué tan rápido pasará de 0 a la capacidad de carga o viceversa.
 - m: Es un parámetro de compensación. Define el punto de inflexión de la función, es decir, cuando cambia de concavidad.

$$g(t) = \frac{C}{1 + e^{-k(t-m)}} \quad (32)$$

- Modelo Lineal por Partes: Para pronosticar problemas que no muestran un crecimiento saturado, existe una tasa de crecimiento constante por partes. δ : tiene los ajustes de tarifas
k: es la tasa de crecimiento

m: es el parámetro de compensación, en estos casos, los puntos de quiebre. Los puede definir el usuario o los puede calcular Prophet.

$$g(t) = (k + a(t)^T \delta)t + (m + a(t)^T \gamma) \quad (33)$$

2. **Ajuste estacional $s(t)$.** Se hace utilizando series de Fourier. Fourier demostró que cualquier función periódica puede formarse a partir de una suma infinita de senos y cosenos.

$$s(t) = \sum_{n=1}^N [a_n \cos(\frac{2n\pi}{T}t) + b_n \sin(\frac{2n\pi}{T}t)] \quad (34)$$

3. **Término $h(t)$.** Queda definido por el usuario, y son aquellos valores que pueden llegar a alterar la serie temporal. Por ejemplo: La llegada del verano altera las ventas de una heladería, los hechos históricos importantes, los fin de semana largos en la venta de vuelos, etc.
4. **Error ϵ_t .** Se estima por diferencia.

5.2. Incertidumbre

Prophet contempla los casos donde se presenta la incertidumbre en la serie y la clasifica de 3 formas:

- Incertidumbre en la tendencia: Prophet puede adaptarse a los cambios de tendencia, pero no anticiparlos. Por ello, asume que en el futuro vendrán cambios de tendencia similares a los de su historia. Esto se calcula con la magnitud, frecuencia y distribución de dichos cambios.
- Incertidumbre en la estacionalidad: Por defecto, Prophet asume que no habrá incertidumbre en la estacionalidad, ya que requiere de un muestreo bayesiano completo.
- Ruido de observación adicional: Es todo valor, adicional a las incertidumbres, que hacen que nuestra predicción difiera de la realidad.

6. Metodología

En primer lugar, se obtuvo los datasets para las criptomonedas BTC, ETH y ADA. Se estipuló la extracción para diferentes periodos de tiempo, eligiendo periodos de un día y treinta minutos para cada moneda. Los datos varían entre el 09-11-2017 y 08-03-2022 para el primer caso y 09-02-2022 y 09-03-2022 para el segundo.

Además, se realizó predicciones con periodos de tiempo al azar tomando:

- Diez periodos de treinta días, para predecir siete días;
- Diez periodos de siete (ARIMA) y ocho (Prophet) días, para predecir siete días.

A cada predicción se le extrajeron métricas.

Finalmente, se eligió cuatro periodos de tiempo al azar para los datos del Bitcoin: se comparan sus métricas y la correlación entre la predicción y el valor real, luego entre las predicciones entre sí.

7. Análisis de Resultados

7.1. Métricas

Un pequeño apartado dedicado a mostrar las métricas de precisión para las series temporales que se utilizarán.

- Mean Absolute Error [MAE]

Fácil de entender y computar. Recomendada para evaluar la precisión de una sola serie pero para comparar distintas series, con distintas unidades, no es adecuado.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

- Mean Absolute Percentage Error [MAPE]

Las ventajas de MAPE son su independencia de escala y su fácil interpretación. Al ser una métrica de porcentaje, se puede usar para comparar el resultado de múltiples modelos de series temporales con diferentes escalas. Sin embargo, tiene como desventaja generar valores infinitos o indefinidos para valores reales cero o cercanos a cero.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

- Root Mean Square Error [RMSE]

Esta medida es la raíz del promedio de los cuadrados del error de cada artículo en el periodo elegido. Es sensible a los valores atípicos. Se utiliza para comparar la precisión de diferentes métodos de predicción.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

7.2. $ARIMA(p, d, q)$

Determinar adecuadamente los parámetros p , q , d bajo los supuestos de $ARIMA$ es el objetivo antes de realizar algún pronóstico de la serie temporal.

En la figura 1 (a) se aplica los valores $d = \{1, 2, 3\}$ sobre la serie del Bitcoin. El resultado de los correlogramas (b) no difiere en gran medida. Sin embargo, el comportamiento deseado es una tendencia decreciente (ver **2.3**): $d = 1$ cumple este requisito, pero a medida que las diferenciaciones aumentan, la tendencia es de crecimiento.

La figura 2 es el correlograma parcial (proveniente de la función de autocorrelación parcial) para $p = \{1, 2\}$. El comportamiento deseado es aquel donde los valores superen la zona de significancia (región azul). Si bien en ambos casos el valor de p cumple las condiciones, elegir $p = 2$ superaría lo esperado con creces.

Finalmente, la función de autocorrelación indica cuantos términos de medias móviles se requieren para eliminar cualquier autocorrelación en la serie estacionaria. La figura 3(a), de orden 1, es adecuada por tener la mayoría de sus valores por debajo del nivel de significancia. Aumentando el orden, los valores escapan de este requisito (b).

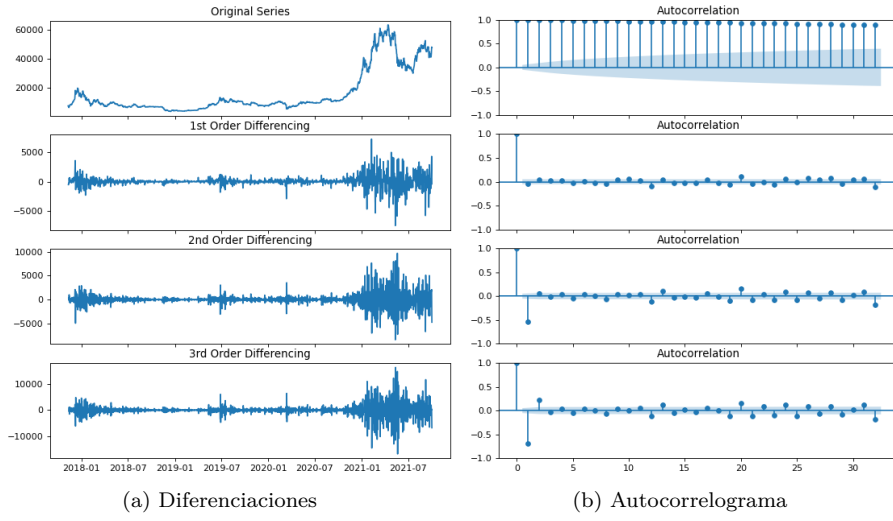


Figura 1: Sucesivas diferenciaciones y efecto en el autocorrelograma para la serie temporal de BTC con periodo de 1 día.




Figura 2: Correlograma parcial de la diferenciación para el parámetro p

Con el fin de no extender y abrumar con gráficos y aún validar lo expuesto, para los restantes datasets se exhibirán los gráficos con los parámetros p y q elegidos, y la estacionariedad al variar d en el Anexo I. En todos se encuentra un patrón común: $ARIMA(2, 1, 1)$




Figura 3: Correlograma de la diferenciación para el parámetro q

7.2.1. Predicciones aleatorias

Los gráficos (figura 4) corresponden a el precio en un periodo de siete días del Bitcoin (tomados diez veces aleatoriamente), más otros siete días donde se compara la predicción del modelo y los valores reales. Las métricas pueden verse en el cuadro (1)

En tanto, la figura 5 recoge la misma información que los gráficos previamente presentados a excepción del modelo, que entrena con periodos de treinta días seleccionados aleatoriamente.

Los datasets utilizados fueron aquellos con periodos de un día.

Los entrenamientos correspondientes a las criptomonedas ADA y ETH se encuentran en el Anexo II.

Métrica	(a)	(b)	(c)	(d)	(e)	(f)	(g)	(h)	(i)	(j)
MAE	3886	4243	3088	268.4	600.9	2476	1495	90.04	418.8	3001
RMSE	4499	4703	3573	290.1	680.4	2817	1611	107.5	506.8	3276
MAPE	0.526	0.074	0.050	0.023	0.055	0.051	0.044	0.023	0.048	0.250

Cuadro 1: Métricas de la figura 4

Para nuestro análisis, tomaremos los ejemplos más significativos: 4(a), 4(b) y 4(d).

MAE se define como el promedio de los errores absolutos para cada una de las observaciones. Implícitamente podemos intuir que un valor mayor para la métrica es consecuencia de un conjunto de predicciones bastante alejados de la realidad, o la presencia de puntos anómalos. La figura (b) muestra con claridad que la predicción no es nada buena. Del mismo modo, según el cuadro 1, le corresponde el valor más alto conferido por la métrica respecto a las demás observaciones. Por otro lado, la figura (d) contiene predicciones más cercanas (al menos, de forma relativa): buscando la métrica, vemos que corresponde a una de las más bajas.

¿Podemos concluir que valores más bajos de MAE sugieren una mejor predicción?

No. El problema de afirmar la pregunta es que ignora la evolución de los precios. Sin dudas obtendríamos la métrica increíblemente baja si tomamos algún periodo del 2017 en lugar de algún periodo de 2021. Particularmente, al obtener valores tan altos, sí podría señalarnos que la predicción no es la deseada.

Métrica	(a)	(b)	(c)	(d)	(e)	(f)	(g)	(h)	(i)	(j)
MAE	1924	255.9	186.1	1003	756.4	268.8	2692	588.8	233.9	121.2
RMSE	2264	335.8	235.0	1111	897.0	309.9	2970	753.8	418.3	125.9
MAPE	0.054	0.024	0.019	0.017	0.017	0.053	0.083	0.048	0.024	0.019

Cuadro 2: Métricas de la figura 5

La métrica MAPE es una medida porcentual² cuyos valores más pequeños indican un mejor ajuste. El gráfico (a) acierta correctamente en esto, otorgando un 52,6% de error a la predicción. En línea con lo anterior, observamos que para (b) otorga un 7.4% -un valor, a simple vista, realmente malo- y para (d) un 2.3%, quizás más aceptable subjetivamente.

7.3. Prophet

7.3.1. Predicciones Aleatorias

Los ajustes fueron generados automáticamente por Prophet, incluyendo los puntos de cambio de tendencia. Vemos que, si bien este ajuste no fue malo, puede mejorar o aproximarse más a los resultados reales si determinamos una mayor flexibilidad en estos puntos de corte.

Hay mucha incertidumbre en los modelos con poco entrenamiento. Esto se ve reflejado en las métricas publicadas, las cuales mejoraron al ampliar el conjunto de entrenamiento.

Esta biblioteca funciona muy bien siempre y cuando los datos no presenten alta frecuencia ni horizontes de predicción muy cortos, ya que los datos pueden no ser suficientes para determinar la estacionalidad o pueden variar mucho como para establecer la periodicidad (ver figura 7(f) respecto a (h)).

Métrica	(a)	(b)	(c)	(d)	(e)	(f)	(g)	(h)	(i)	(j)
MAE	65.19	1616	2386	25018	9654	14195	633.9	78.68	1803	3678
RMSE	65.19	1616	2386	25018	9654	14195	633.9	78.68	1803	3678
MAPE	0.017	0.032	0.293	0.402	0.149	0.379	0.063	0.012	0.265	0.087

Cuadro 3: Métricas de la figura 6

7.4. Comparación de Modelos

Como se adelantó previamente, para esta comparativa se eligió cuatro periodos de treinta días de entrenamiento para cada modelo. Los pronósticos son a siete días y se pueden observar en la figura 11.

Las métricas obtenidas (figuras 8, 9, 10) son las utilizadas con anterioridad pero esta vez junto al coeficiente de correlación (ver 1.2.2). Este coeficiente es una medida de dependencia lineal entre dos variables aleatorias³. Un valor $0 < |r| < 1$ indica una fuerza mayor entre las variables involucradas. El signo

²Los datos recopilados en el cuadro, sin embargo, no están expresados porcentualmente.

³https://es.wikipedia.org/wiki/Coeficiente_de_correlacion_de_Pearson

Métrica	(a)	(b)	(c)	(d)	(e)	(f)	(g)	(h)	(i)	(j)
MAE	62931	20152	196094	19753	34188	11018	246692	21603	62265	26942
RMSE	87618	27940	274664	27251	45858	15213	174472	30480	85150	36169
MAPE	7.543	3.136	4.508	2.217	4.099	1.590	18.68	5.589	1.108	1.49

Cuadro 4: Métricas de la figura 7

de r es significativo en otros contextos a excepción del presente, por lo cual se ignora con el fin de presentar el gráfico de barras.

Como puede apreciarse en la figura, se calcula la correlación para los pares ARIMA-Actual (valores reales), Prophet-Actual y ARIMA-Prophet. Este último con el fin de determinar la diferencia (o igualdad) de sus pronósticos.

- La correlación (figura 8(a)) para la predicción 11(a) nos da valores relativamente altos e iguales. Entre ellos, Prophet es el más acertado en la cercanía de curvas. Sin embargo, el coeficiente es cercano al de ARIMA, cuyo desempeño es malo.

Para las restantes predicciones, ARIMA no brinda información relevante (11(b), (c), (d)) variando el coeficiente en valores muy bajos, medios y relativamente altos (8(b), (d) y (c) respectivamente). Prophet, en cambio, logra un desempeño más aceptable, capturando dos tendencias (11(c) y (d)) con un coeficiente mayor a 0.5 y una negativa total en (b) cuyo coeficiente es muy cercano a 0.

- La métrica MAE, en Prophet, acierta considerablemente respecto a 11(a), (b) y (d), con valores altos y bajos, aunque (d) es cuestionable al existir diferencias contrarrestadas entre los primeros tres días y los cuatro restantes. Un caso interesante es la cercanía de curvas en (c): a pesar del poco error entre cada punto, la media entre ellos tiende a crecer por la tendencia de la serie.

La métrica para el modelo ARIMA es consistente únicamente en 11(b). Aprecié (d); es esperable un MAE más alto (alrededor de 3000) pero la presencia de una predicción muy cercana altera totalmente el resultado.

- MAPE, recordando que se entiende de una medida de error de pronóstico, no es acertado en ARIMA: 11(b) indicaría que existe un 2 %, en promedio, de error de pronóstico pero para 11(d) un 6 % (algo no plasmado en el gráfico, irónicamente).

En Prophet se observa resultados más aceptables; incluso el mayor valor 10(d) corresponde con errores mayores. Particularmente, 10(b) no exhibe lo que muestra 11(b) explicable por los valores reales muy por encima de los predecidos.

8. Conclusión

Los dos modelos estudiados se rigen bajo un principio que las series temporales de las criptomonedas analizadas no cumplen: la estacionalidad. Si bien

mediante técnicas se busca que estas series alcancen la misma, en la práctica se observa que tienen limitaciones altísimas, aunque con alguna excepción digna por parte del modelo generado por Prophet capturando tendencias pero generando el sentimiento contrario al encontrarse con comportamientos de alza o bajada extremos, como frecuentemente sucede en este tipo de mercados.

Las métricas, por su parte, han respondido en ocasiones muy bien -hablando exclusivamente de Prophet- aunque existen predicciones donde el ajuste de la curva no respondía numéricamente a ninguna de las métricas utilizadas. Es menester validar de forma más extensa el objetivo de este informe partiendo de modelos más complejos que ARIMA, tal como lo es Prophet, con la certeza de tener métricas que acompañan el proceso.

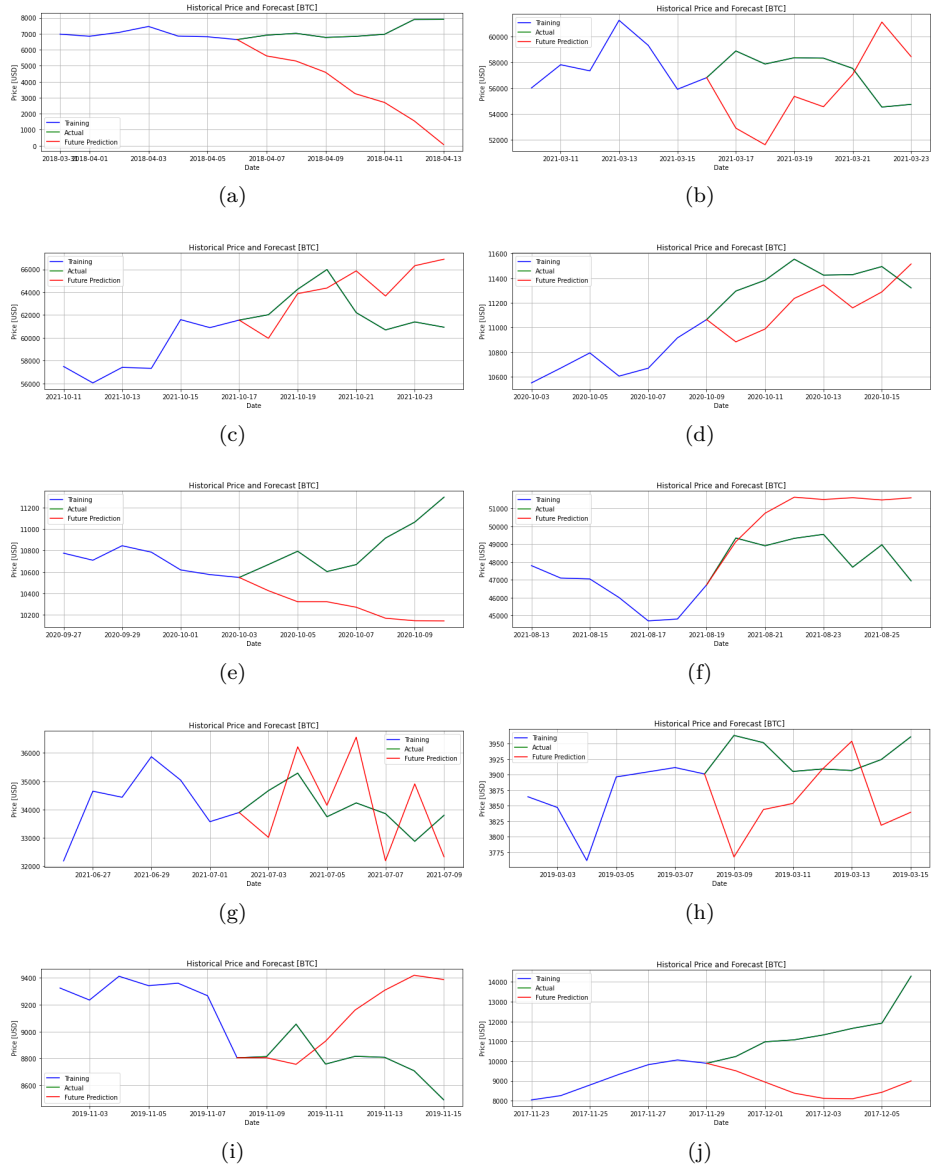


Figura 4: Predicción del modelo entrenado con 10 semanas aleatorias de BTC




Figura 5: Predicción del modelo entrenado con 10 meses aleatorios de BTC

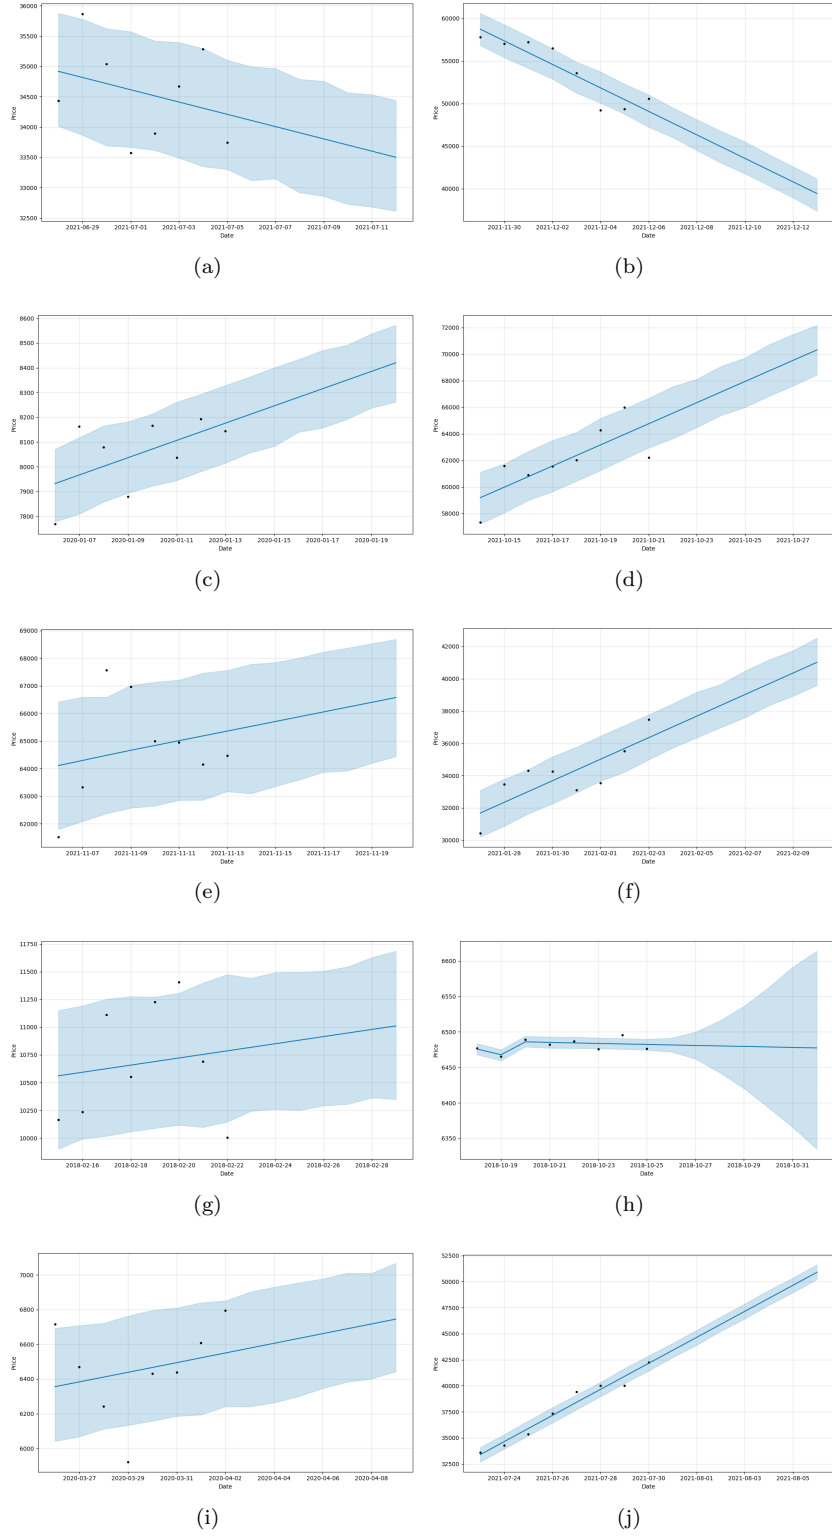


Figura 6: Predicción del modelo entrenado con 10 semanas aleatorias de BTC

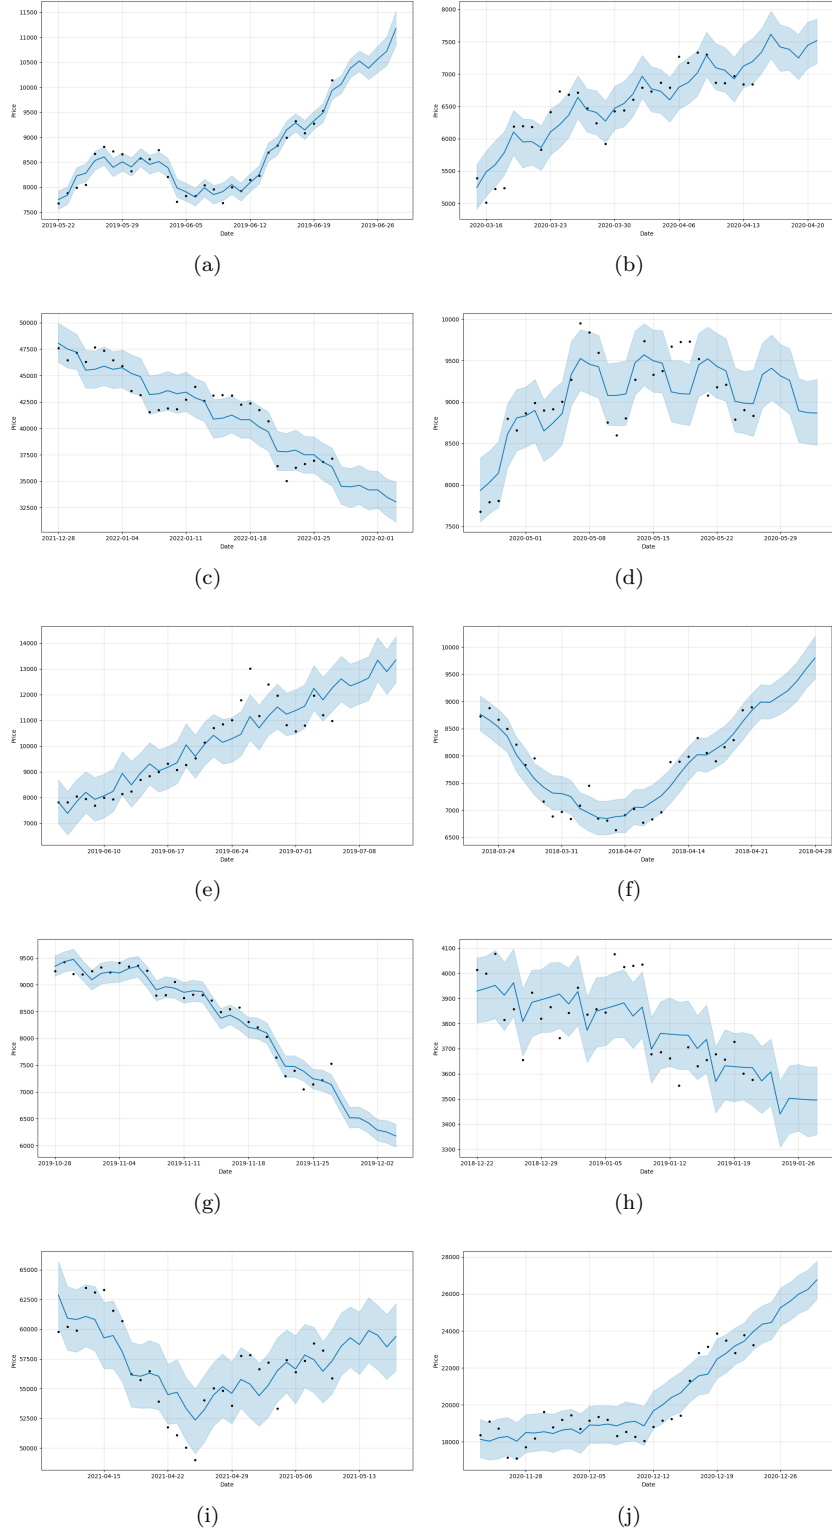


Figura 7: Predicción del modelo entrenado con 10 meses aleatorios de BTC




Figura 8: Coeficiente de correlación para las predicciones de la figura 11




Figura 9: Métrica MAE para las predicciones de la figura 11




Figura 10: Métrica MAPE para las predicciones de la figura 11

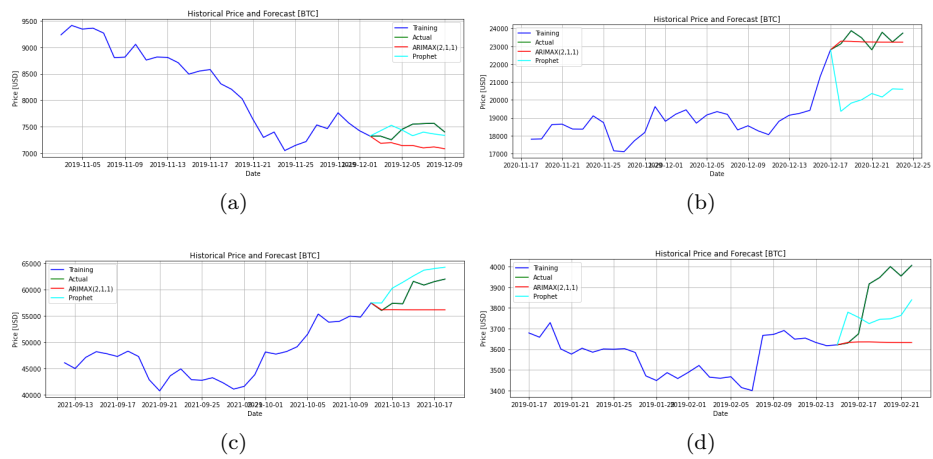


Figura 11: Cuatro predicciones del BTC de ambos modelos